

[산학 프로젝트 트랙]

Qureka

자기주도 학습을 하는 대학생을 위한,
강의자료 기반 개인 맞춤형 소크라테스식 질문을 생성하여
사고의 확장을 유도하는 **AI** 튜터링 서비스

팀명	EWIN(35팀)
팀원	2176296 이지원 2076317 이에은 2271016 김우빈
지도교수	심재형

목차

(1) Team Info (팀 정보)

1.1. 과제명

1.2. 팀 정보

1.3. 팀 구성원 및 역할

(2) Project-Summary (과제 요약)

2.1. 문제 정의

2.2. 기존 연구(서비스)와의 비교

2.3. 제안 내용

2.4. 기대 효과 및 의의

2.5. 주요 기능 리스트

(3) Project-Design & Implementation (과제 설계)

3.1. 요구사항 정의

3.2. 전체 시스템 구성

3.3. 주요 엔진 및 기능 설계

3.4. 주요 기능의 구현

3.5. 기타

[1차 보고서: QUREKA 시스템 제안 및 설계서]

(1) Team Info (팀 정보)

1.1. 과제명

- Qureka - 자기주도 학습을 하는 대학생을 위한, 강의자료 기반 개인 맞춤형 소크라테스식 질문 생성 AI 튜터링 서비스

1.2. 팀 정보

- Team 35 EWIN

1.3. 팀 구성원 및 역할

- 이지원 **(BE)**: FastAPI 기반 API 서버 설계, 멀티모달(PDF/STT/OCR) 데이터 전처리 파이프라인 구축, 벡터 DB(pgvector) 연동 및 JSON Web Token 인증 시스템 구현
- 김우빈 **(AI)**: Retrieval-Augmented Generation 기반 컨텍스트 검색 알고리즘 최적화, 학습자 맞춤형 소크라테스식 질문 생성 프롬프트 설계, 핵심 개념 빈도 및 학습 흐름 분석 로직 개발
- 이예은 **(FE)**: React 기반 실시간 채팅 인터페이스 구현, 파일 업로드 UI 개발, 학습 사고 흐름 시각화를 위한 마인드맵 라우팅 및 UI 폴리싱

(2) Project-Summary (과제 요약)

2.1. 문제 정의

■ 목표 사용자

- 단순한 지식 습득이나 단기적 암기를 넘어, 전공 지식의 근본적인 원리를 파악하고 이를 다각도로 분석할 수 있는 비판적 사고력을 기르고자 하는 자기주도형 대학생입니다.

■ 현황 및 문제점 (Pain Points)

1. 파편화된 멀티모달 학습 자료를 통합 관리할 수 없는 환경의 불편함

- 강의 자료 PDF, 학생 개개인의 손필기, 강의 음성 녹음 파일 등 다양한 형태의 자료를 유기적으로 연결할 환경이 부족합니다. 이로 인해 학생들은 필요한 정보를 찾기 위해 여러 앱이나 기기를 번거롭게 오가야 하며, 그 과정에서 학습의 흐름이 끊기고 과도한 시간적 비용이 발생합니다.

2. 생성형 AI의 '즉각적 정답 제공'으로 인한 능동적 학습 기회 상실

- 대다수의 AI 서비스는 질문을 던지면 완성된 요약본이나 정답을 즉시 알려주는 방식입니다. 이러한 방식은 과제를 빨리 끝내거나 정보를 급하게 찾을 때는 편리하지만, 학생 스스로 원리를 추론하고 고민하는 과정이 생략되어, 지식을 완전히 자신의 것으로 소화하는 능동적인 공부 습관을 형성하는 데 방해가 됩니다.

3. 학습 과정의 객관화 부재와 메타인지 파악의 어려움

- 학습 과정에서 자신이 어느 지점에서 논리가 어긋났는지, 혹은 어떤 개념을 모호하게 알고 넘어갔는지를 스스로 파악하기란 매우 어렵습니다. 기존의 학습 도구들은 학습자가 정답에 도달하기까지 어떤 사고 과정을 거쳤는지 기록하거나 분석해 주지 않습니다. 이로 인해 자신이 무엇을 알고 무엇을 모르는지(메타인지)를 정확히 알지 못한 채, 이미 아는 내용만 반복하거나 취약한 부분을 놓치는 비효율적인 복습을 반복하게 됩니다.

2.2. 기존 연구(서비스)와의 비교

■ 본 과제와 유사한 기능을 제공하는 기존의 AI 서비스들을 '범용 대화형 AI'와 '문서 기반 학습 도구' 두 가지 군으로 분류하여 분석하였으며, 각 서비스의 한계점을 극복하기 위한 Qureka만의 기술적/학습적 우위성을 다음과 같이 정리하였습니다.

비교 대상	주요 특징 및 장점	한계점 및 단점
비교군 1: 범용 대화형 AI (예: ChatGPT, Claude 등)	• 방대한 데이터를 바탕으로 일반적인 지식에 대해 수준 높은 질의응답이 가능함. • 자연어 처리 능력이 뛰어나 일상적인 대화나 복잡한 문장 구조를 잘 이해함.	• 질문자가 대화를 주도해야 하므로 명확한 학습 목표가 없는 경우 단순 정보 검색에 그치기 쉬움. • 사용자가 업로드한 특정 강의 자료의 세부 맥락(손필기, 음성 녹음 등)을 깊이 있게 반영하는 데 한계가 있음.
비교군 2: AI 문서 요약 도구 (예: Slid, Quizlet 등)	• PDF나 영상 자료를 입력하면 핵심 내용을 요약하거나 퀴즈, 플래시카드로 빠르게 변환해 줌. • 단시간에 많은 양의 정보를 훑어보거나 암기 위주의 공부를 할 때 효율적임.	• 정답이나 요약본을 즉시 제공하는 '결과 중심적' 서비스로, 학습자의 수동적인 콘텐츠 소비를 유도함. • AI가 정답을 바로 알려주기 때문에 학습자가 스스로 사고하고 추론할 기회가 부족함.

QUREKA 시스템의 차별성 및 장점

1. 멀티모달 RAG 기술 기반의 정교한 강의 문맥 이해

- 차별점: 단순 PDF 텍스트 추출을 넘어, 학생의 개인 손필기 이미지(OCR)와 교수님 음성(STT) 데이터를 단일 벡터 공간에서 통합 분석합니다.
- 장점: pgvector를 통해 수업 중 언급된 세부 맥락이나 개인적인 메모까지 벡터화하여 대화에 반영하기 때문에, 실제 강의 현장과 가장 밀접한 초개인화된 튜터링 환경을 제공합니다.

2. 소크라테스식 문답법을 통한 능동적 학습 메커니즘의 구현

- 차별점: 질문에 즉각적인 해설을 제공하는 기존 AI 서비스들과 달리, 학습자가 스스로 논리적 모순을 깨닫고 정답을 도출하도록 유도하는 '단계별 힌트 및 역질문 로직'을 핵심 엔진으로 합니다.
- 장점: **System Prompt 설계를 통해** 지식의 단순 암기를 넘어 비판적 사고력을 함양하며, 능동적인 자기주도 학습 습관 형성을 돕습니다.

구분	범용 대화형 AI 첫 번째 질문입니다. Q1. 아래의 시스템 요구사항 예시를 보고, 이것이 '기능적 요구사항'인지 '비기능적 요구사항'인지 맞춰보세요. "사용자는 상품 상세 페이지에서 '장바구니 담기' 버튼을 클릭하여 상품을 저장할 수 있어야 한다." 이 요구사항은 어디에 해당할까요? 이유도 함께 생각해 보시면 공부에 더 도움이 됩니다! 비기능적 요구사항 오, 이런! 다시 한번만 살펴볼까요? 🤔 정답은 ***기능적 요구사항***입니다. 조금 헷갈릴 수 있지만, 구별하는 아주 쉬운 팁이 있어요! ● 기능적 요구사항: "시스템이 **무엇(What)**을 하는가?" (사용자가 버튼을 눌렀을 때 일어나는 구체적인 동작) ● 비기능적 요구사항: "시스템이 어떻게(How) 작동하는가?" (얼마나 빠르냐, 얼마나 안전한지 등의 품질/조건)	Qureka Qureka: 아래의 시스템 요구사항 예시를 보고, 이것이 '기능적 요구사항'인지 '비기능적 요구사항'인지 맞춰보세요. "사용자는 상품 상세 페이지에서 '장바구니 담기' 버튼을 클릭하여 상품을 저장할 수 있어야 한다." 이 요구사항은 어디에 해당할까요? 이유도 함께 생각해 보시면 공부에 더 도움이 됩니다! 🧐+2 정답이라고 생각하시는 범주와 그 이유를 말씀해 주세요! 비기능적 요구사항 강의 자료의 예시를 보면, "사용자는 로그인 후 주문 내역을 조회할 수 있어야 한다"는 내용은 시스템이 수행해야 하는 행위이므로 기능적 요구사항으로 분류됩니다. 반면 비기능적 요구사항은 "2초 이내 응답"과 같은 성능이나 "데이터 암호화"와 같은 보안 등 시스템의 품질 및 제약조건을 의미합니다. 🧐+1 방금 제시된 ***장바구니 담기* 버튼을 클릭하여 상품을 저장하는 것***은 시스템이 사용자에게 제공해야 하는 구체적인 '행위'에 해당할까요, 아니면 '성능'이나 '보안 수준'에 해당할까요? 🧐+1 강의 자료의 기준에 따라 이 요구사항은 어느 범주에 더 적합한지 다시 답변해 주시겠어요? 🧐+1
응답 방식	결과 중심적 (즉각적인 정답 제시)	과정 중심적 (단계적 추론 유도)
피드백 전략	사용자의 오답을 즉시 정정하고 이론적 설명을 일방적으로 제공함.	오답의 원인을 스스로 찾을 수 있도록 강의 자료 기반의 '힌트 질문'을 역으로 제시함.
학습 효과	단순 지식 전달에 그치며, 사용자가 깊게 생각할 기회를 차단함.	사용자가 자신의 논리를 재검토하게 하여 비판적 사고 및 메타인지를 자극함.

3. 사고 경로의 데이터화 및 시각적 학습 리포트 제공

- 차별점: 단순 대화 기록 저장을 넘어, 대화 로그를 분석하여 핵심 개념 간의 관계를 보여주는 개념 트리(Concept Tree)와 학습자의 이해도 타임라인(Confusion/Progress)을 시각화하여 생성합니다.
- 장점: **React-Flow 또는 마인드맵 UI를 통해** 학습자가 본인의 취약 지점과 이해도를 객관적인 데이터로 확인하게 함으로써, 막연한 복습이 아닌 '모르는 부분'에 집중하는 효율적이고 전략적 메타인지 학습을 실현합니다.

2.3. 제안 내용

■ 본 과제는 AI가 정답을 일방적으로 주입하여 학습자의 사고를 제한하는 기존 방식에서 탈피하여, '소크라테스식 문답법'을 기반으로 학습자 스스로 논리적 허점을 발견하고 지식을 구조화할 수 있도록 돕는 지능형 AI 튜터링 웹 플랫폼, QUREKA를 제안합니다. 본 프로젝트는 AI와의 실시간 문답과 학습 리포트를 시각화하여 제공하는 웹 기반의 서비스 구현을 최종 산출물로 합니다.

1. 멀티모달 데이터 통합 및 지식 베이스(Knowledge Base) 구축

- 학습 자료의 파편화 문제를 근본적으로 해결하기 위해 **FastAPI 기반의 데이터 전처리 파이프라인을 구축하여** 강의 PDF, 태블릿 손필기 이미지(OCR), 교수님 음성 녹음(STT) 등 다양한 비정형 데이터를 하나의 학습 맥락으로 통합합니다.
- 각기 다른 형태의 자료에서 추출된 텍스트는 의미 단위(Chunk)로 분할된 후, 벡터 임베딩 과정을 거쳐 벡터 데이터베이스(Vector DB)에 저장됩니다. 이를 통해 학습자는 어떤 형태의 자료를 업로드하더라도, AI 튜터가 전체 강의 내용을 완벽히 숙지한 상태에서 일관된 답변을 제공하는 '통합형 학습 환경'을 경험하게 됩니다.

2. 소크라테스식 대화 유도를 위한 고도화된 프롬프트 엔지니어링

- 기존 생성형 AI의 즉각적인 정답 제시로 인해 발생하는 학습자의 수동적 의존성 문제를 해결하기 위해, **Gemini API에 '정답 제시 금지' 및 '역질문 원칙'을 강제하는** 고도화된 프롬프트 로직을 설계합니다. AI 튜터는 학습자가 질문하기를 기다리는 것이 아니라, 업로드된 자료의 핵심 개념을 바탕으로 먼저 정교한 질문을 던짐으로써 대화를 주도합니다.

3. 학습자 맞춤형 인지 상태 분석 및 동적 답변 처리 로직

- 학습자 스스로 자신의 논리적 허점이나 모호한 개념을 인지하지 못하는 '메타인지 부재' 문제를 해결하기 위해, 단순한 정오답 판별을 넘어 학습자의 현재 이해도에 따라 질문의 난이도와 방향을 동적으로 결정하는 시스템을 구현합니다.
- 학습자의 답변이 정확할 경우, 해당 개념의 상위 원리나 실제 사례와의 연결성을 묻는 '확장형 질문'을 던져 지식의 깊이를 더하는 심화 사고를 유도합니다. 반면 오답이나 모호한 답변이 입력될 경우, AI가 오류를 직접 지적하는 대신 관련 기초 개념으로 되돌아가는 '힌트 질문'이나 '비교 질문'을 제공합니다.

4. 사고 경로 시각화 및 메타인지 강화를 위한 학습 리포트 시스템

- 학습 과정이 실시간으로 기록되지 않고 휘발됨에 따라, 복습 시 자신의 취약 지점을 정확히 파악하지 못해 발생하는 비효율적인 학습 문제를 해결하기 위해 대화 종료 후 학습 데이터를 정량적으로 분석한 시각적 피드백 리포트를 제공합니다. 이는 단순한 대화 로그 저장을 넘어, 학습자가 거처온 사고의 궤적을 객관적인 지표로 변환하여 제공하는 시스템입니다.
- 먼저, 대화 중 다루어진 핵심 키워드 간의 유기적 관계를 마인드맵 형태로 시각화한 '개념 트리(Concept Tree)'를 생성하여 지식의 체계적인 구조화를 돕습니다. 이와 동시에 전체 대화 흐름 속에서 학습자가 논리적 혼동을 느꼈던 지점(Confusion)과 이해가 완성된 지점(Progress)을 분석하여 '이해도 타임라인'으로 제시합니다.

2.4. 기대 효과 및 의의

1. 통합 학습 환경 제공을 통한 학습 흐름의 연속성 확보

- PDF, 손필기, 음성 녹음 등 흩어져 있던 다양한 형태의 자료를 한곳에서 통합적으로 다룸으로써, 자료를 찾거나 기기를 교체하는 과정에서 발생하는 주의력 분산을 방지합니다.
- 학습자는 외부적인 불편함 없이 오직 '학습의 내용'에만 온전히 몰입할 수 있는 환경을 보장받으며, 이는 실제 학습 시간의 밀도를 높여주는 실질적인 학업 환경 개선 효과를 가져옵니다.

2. 능동적 참여를 통한 자기주도적 학습 습관의 정착

- AI 튜터가 정답을 대신 찾아주는 기존의 검색 중심 방식에서 벗어나, 학습자가 스스로 강의 자료를 재탐색하고 논리를 구성하여 답변을 도출하도록 유도합니다.
- 이러한 반복적인 문답 과정은 학습자가 공부의 주도권을 갖게 하며, 단순히 내용을 수동적으로 수용하는 것보다 훨씬 높은 집중력을 유지하게 하여 장기적으로 능동적인 학습 습관을 형성하는 데 기여합니다.

3. 논리적 사고력 강화 및 전공 지식의 체계적 구조화

- "왜 그렇게 생각하나요?"와 같은 AI의 역질문에 답하는 과정에서 학습자는 파편화된 지식들을 연결하여 하나의 완성된 논리 체계를 세우는 연습을 하게 됩니다.
- 이는 전공 지식의 단편적인 암기를 넘어, 개념 간의 인과관계를 파악하고 이를 자신의 언어로 정리하는 능력을 길러주며, 복잡한 이론을 체계적으로 구조화하여 이해하는 능력을 함양시킵니다.

4. 사고 경로 데이터화를 통한 메타인지 향상 및 복습 효율의 극대화

- 대화 세션 종료 후 제공되는 사고 경로 리포트(개념 트리, 타임라인 등)를 통해 학습자는 자신의 학습 과정을 객관적인 데이터로 확인하게 됩니다.
- 이를 통해 본인이 '정확히 이해한 부분'과 '답변 과정에서 논리가 꼬였던 지점'을 명확히 구분하는 메타인지(**Metacognition**) 능력을 높일 수 있습니다. 결과적으로 막연한 전체 복습이 아닌, AI가 분석해 준 취약 지점을 공략하는 전략적 학습이 가능해져 시간 대비 학습 효율이 비약적으로 상승합니다.

2.5. 주요 기능 리스트

1. 멀티모달 학습 자료 통합 전처리 (정확도 90% 이상 목표)

- 1) **PDF/ 손글씨 이미지 OCR 추출**: 강의 PDF 및 Gemini API를 통한 손필기 이미지 내 텍스트 인식
 - 2) 강의 음성 **STT** 변환: Whisper 모델을 활용한 교수님 음성 데이터의 디지털 텍스트화
 - 3) 데이터 청킹 및 벡터화: 추출된 데이터를 의미 단위(Chunk)로 분할하여 pgvector DB 저장
- 현황: 현재 PDF/이미지/음성 각 소스별 텍스트 추출 모듈의 개별 구현을 완료하였으며, 내부 테스트 결과 높은 인식률을 확인하였습니다. ~~단, 대규모 데이터 처리 시 Gemini API 호출의 비용 효율성 문제를 개선하기 위해, NAVER CLOVA OCR 또는 Google Cloud Vision 등 OCR 전문 엔진으로의 전환 및 비교 테스트를 진행 중입니다.~~ 또한, 운영 비용 최적화를 위해 **NAVER CLOVA OCR** 도입을 검토하고 성능 비교 테스트를 실시하였습니다. 그러나 테스트 결과, 손글씨 인식에 있어 인식률이 기대치에 크게 미달함을 확인하였습니다.
 - 따라서 비용 절감보다 데이터의 정확성이 소크라테스식 학습 모델의 품질을 결정짓는 핵심 요소라고 판단하여, 멀티모달 이해도가 가장 뛰어난 **Gemini API** 기반의 **OCR** 엔진을 최종 확정하여 사용하기로 결정하였습니다.

- 또한, **OCR** 및 **STT** 과정에서 발생할 수 있는 인식 오류를 해결하기 위해, 추출된 텍스트를 학습자가 직접 확인하고 수정할 수 있는 데이터 검증 인터페이스 기능을 설계하였습니다. 현재 백엔드에서의 데이터 수정 및 재저장 로직 구현은 모두 완료되었으며, 학습자가 편리하게 오타를 교정할 수 있도록 돕는 프론트엔드 편집 **UI** 연동 작업을 진행 중입니다.
- 이를 통해 ~~운영 비용을 최적화함과 동시에~~ 한국어 손글씨 및 복잡한 수식에 대한 인식 정확도를 **90%** 이상으로 확보하는 것을 최종 목표로 합니다.

2. RAG 기반의 소크라테스식 **AI** 대화 엔진

- 1) **RAG** 기반의 문맥 정보 검색: 사용자 질의와 연관된 강의 맥락을 벡터 **DB**에서 실시간 검색하고, **RAG** 기술을 적용하여 업로드된 자료의 지식 범위 내에서만 답변을 생성하도록 제어. 근데
 - 2) 맞춤형 소크라테스식 튜터링 구현: 직접적 정답 노출을 차단하는 역질문 프롬프트를 강제 적용하고, 사용자의 전공 및 학업 수준에 최적화된 학습 가이드를 제공.
 - 3) 학습 인지 상태별 동적 피드백: 학습자의 답변 결과에 따라 정답 시 상위 원리를 묻는 '확장형 질문'으로 심화 사고를 유도하고, 오답 시 직접적 교정 대신 기초 개념 기반의 '힌트 질문'을 제공하여 자가 교정을 조력.
- 현황: **pgvector** 기반 벡터 유사도 검색 로직 구현 및 학과별 페르소나 프롬프트 설계 완료하였으며, ~~현재 대화의 맥락 유지 및 역질문 유도 성능을 최적화하고 있습니다.~~ 소크라테스식 역질문 생성 과정에서 발생하는 간헐적인 **API** 응답 오류 및 타임아웃 문제를 해결하기 위한 최적화를 진행 중입니다.
 - 해당 오류의 주요 원인이 프롬프트의 제약 조건(정답 노출 금지 등)이 복잡해짐에 따라 발생하는 모델의 추론 부하 및 출력 형식 불안정성에 있음을 확인하였습니다. 이를 개선하기 위해 프롬프트 구조를 모듈화하고, **API** 호출 시 예외 처리 로직과 **JSON** 파싱 검증 절차를 강화하여 시스템의 안정성을 확보하는 단계에 있습니다.

3. 사고 경로 분석 기반의 맞춤형 학습 리포트

- 1) 개념 트리 시각화: 대화 로그 기반 핵심 키워드 간의 관계를 마인드맵으로 생성
 - 2) 이해도 타임라인 분석: 대화 중 '혼동(Confusion)'과 '진전(Progress)' 지점을 추출하여 시각화
- 현황: 대화 로그가 데이터베이스(**ChatMessage** 테이블)에 정교하게 기록되도록 설계를 마쳤습니다. ~~현재 저장된 로그를 분석하여 핵심 키워드를 추출하는 알고리즘을 개발 중이며, ReactFlow를 활용한 시각화 프로토타입을 검토하고~~

있습니다. 또한, 자체적인 단어 빈도 분석과 Gemini AI의 판단을 결합한 방식으로 저장된 로그를 분석하여 핵심 키워드를 추출하는 알고리즘을 완성하였습니다. 이를 통해 추출된 핵심 개념과 연관어들을 **React Flow** 기반의 시각화 엔진 구현을 통해 지식의 구조를 한눈에 파악할 수 있도록 구현 후 테스트 중입니다.

- 학생의 답변 패턴(모르겠어, 이해했어 등)을 실시간으로 감지하여 학습의 흐름을 나열하는 타임라인 기능 또한 구현하였습니다. 특히, AI의 응답이 불안정할 경우 자체 분석 코드가 즉시 가동되는 안전장치(**Fallback**)를 설계하여, 어떤 상황에서도 마인드맵과 타임라인 리포트가 끊김 없이 제공되도록 시스템 안정성을 확보하였습니다.

4. 강의 및 채팅 세션 관리 시스템

- 1) 강의 폴더 및 세션 매핑: 사용자별 강의 자료와 채팅 이력을 체계적으로 폴더링 관리
 - 2) 독립적 문맥 유지: 세션별 독립적인 대화 **Context** 유지 및 과거 이력 복원 기능
- 현황: **FastAPI**와 **PostgreSQL**을 연동하여 회원가입, 로그인 및 강의 자료 업로드 등의 서버 기초 로직과 데이터 저장 구조를 완성하였습니다. 현재 저장된 과거 학습 이력을 사용자별 대시보드에 정확히 불러와 시각화하는 조회 기능(**Read**)을 개발 중입니다. 완료하였습니다.
 - 또한, 학습 세션의 직관적인 관리를 위해 채팅 세션의 제목을 자유롭게 수정하는 기능을 추가 구현하였습니다. 현재는 전체 관리 라이프사이클의 마지막 단계인 강의 자료 및 세션 삭제 기능을 개발 중이며, 이를 통해 데이터 무결성과 관리 효율성을 모두 갖춘 시스템을 완성할 예정입니다.

(3) Project-Design & Implementation (과제 설계)

3.1. 요구사항 정의

본 서비스의 핵심 가치인 '자기주도 학습 지원'을 실현하기 위해 기능적/비기능적 요구사항을 다음과 같이 정의합니다.

■ 기능적 요구사항

1. 멀티모달 학습 자료 통합 업로드: 사용자는 PDF 문서, 이미지(손필기), 음성 녹음 파일(MP3)을 단일 인터페이스를 통해 업로드할 수 있어야 합니다.
1. 데이터 전처리 및 텍스트 추출: 시스템은 PyMuPDF 및 Whisper AI를 활용하여 업로드된 자료에서 텍스트를 추출(OCR/STT)하고 Recursive Splitter을 기반으로 의미 단위로 분할(Chunking)하여 저장해야 합니다.
2. RAG 기반 소크라테스식 튜터링: 사용자 질문 답변 시 L2 Distance 유사도 검색 기반으로 관련 문맥을 검색하고, 직접적인 정답 대신 사고를 자극하는 역질문을 생성해야 합니다.
3. 학습 결과 시각화 및 리포트: 대화 로그를 분석하여 개념 트리와 학습 타임라인(Confusion/Progress)을 D3.js 기반의 Hierarchical JSON 데이터 시각화 리포트로 제공해야 합니다.
4. 학습 이력 관리: 강의별 세션 생성, 대화 로그 저장 및 불러오기 기능을 제공해야 합니다.

■ 비기능적 요구사항

1. 인식 정확성: Gemini 2.5 Flash의 멀티모달 능력을 활용하여 손글씨 및 복잡한 수식에 대한 OCR 인식 정확도를 90% 이상 유지합니다.


2. 응답 지연 시간(**Latency**) 최소화: **FastAPI**의 비동기 처리를 통해 사용자의 질문 입력 후 **AI**의 첫 응답이 시작되기까지의 시간을 5초 내외로 최적화하여 학습의 흐름이 끊기지 않도록 합니다.
3. 데이터 무결성 및 보안: **python-jose(JWT)** 라이브러리를 활용한 토큰 기반 세션 인증 체계를 구축하여 사용자가 업로드한 강의 자료 및 대화 로그는 개인정보 보호 원칙에 따라 안전하게 암호화되어 관리되어야 합니다.
4. 사용자 편의성(**Usability**): 직관적인 **UI/UX**를 설계하여 별도의 매뉴얼 없이도 대학생 사용자가 즉시 학습에 활용할 수 있어야 합니다.

3.2. 전체 시스템 구성

1) 전체 SW 구조

QUREKA는 최신 인공지능 모델과 효율적인 데이터 파이프라인이 결합된 멀티모달 **RAG** 아키텍처로 구성됩니다.

[시스템 아키텍처 구성도]



1. 프론트엔드

- 기술 스택 및 라이브러리: React, JavaScript, HTML/CSS, React Router, [Fetch API](#), [Axios](#), [react-d3-tree](#)(데이터 시각화), [jwt-decode](#)(인증 처리)
- 핵심 역할: 학습 자료 업로드 인터페이스, 소크라테스식 채팅 UI 및 시각화 리포트(마인드맵/타임라인) 제공

2. 백엔드

- 기술 스택 및 라이브러리: FastAPI, Python, SQLAlchemy, python-jose(JWT)

- 핵심 역할: ~~JWT 기반 사용자 인증, 세션/강의 매핑 관리, RAG 파이프라인 제어 및 프롬프트 전략 수립~~
 - **Auth & Lecture App:** JWT 기반 로그인 인증 처리 및 세션 관리, 사용자-강의-세션 간의 관계를 DB에 매핑합니다. API 요청 시 HS256 알고리즘을 사용하여 토큰의 유효성을 검증합니다.
 - **Pipeline App:** 업로드된 멀티모달 파일의 전처리(OCR/STT/이미지 변환)를 수행하고, 의미 단위(Chunk)로 분할하여 벡터 임베딩 후 DB에 저장합니다.
 - **RAG & Chat App:** 사용자 질의에 대해 벡터 DB에서 가장 관련성 높은 문맥(Top-k)을 추출하고, 프롬프트를 결합하여 Gemini API를 통한 소크라테스식 문답을 생성 및 제어합니다.
 - **Report App:** 종료된 세션의 대화 로그를 분석하여 핵심 개념 키워드를 추출하고, 프론트엔드가 렌더링할 수 있도록 노드/엣지 데이터 및 타임라인 JSON 데이터를 가공하여 반환합니다.

3. AI 및 데이터 엔진

- **AI 모델 & 엔진:**
 - **Gemini 2.5 Flash:** 멀티모달 기반 Smart OCR(이미지/손글씨 인식) 및 소크라테스식 문답 생성(LLM) 통합 수행
 - **Gemini-Embedding-001:** 강의 데이터의 고차원 벡터화 및 의미론적 지식 추출
 - **OpenAI Whisper:** 강의 음성 데이터의 정밀 텍스트 변환(STT)
 - **PyMuPDF:** PDF 문서의 시각적 분석 및 ~~텍스트 데이터 추출~~ 고화질 이미지 변환 로직 수행
- **데이터베이스 (Storage):**
 - **PostgreSQL:** 사용자 계정 정보, 강의 메타데이터 및 세션별 대화 로그 관리
 - **pgvector:** 벡터 임베딩 데이터 저장 및 고속 유사도 검색(L2 Distance) 수행 (Docker 기반 구동)

2) 주요 기능에 대한 제어 및 데이터 흐름

- **제어 흐름 (Control Flow):** 사용자의 요청(파일 업로드, 채팅 등)은 FastAPI의 Router를 통해 각 App 모듈로 분기됩니다. 특히 데이터 전처리와 같이 부하가 큰 작업은 비동기(Async) 방식으로 처리되어 시스템의 응답성을 유지합니다.
- **데이터 흐름 (Data Flow):**

1. **(Input)** 사용자가 업로드한 멀티모달 파일이 **Pipeline App**으로 전달됩니다.
2. **(Processing)** OCR/STT를 통해 텍스트화된 데이터는 임베딩 후 **pgvector**에 저장됩니다.
3. **(Interaction)** 사용자 질문 발생 시 **RAG App**이 **DB**에서 관련 지식을 검색하고, 이를 **Gemini API**에 전달하여 답변을 수신합니다. 4. **(Output)** 최종 생성된 답변과 분석된 리포트 데이터가 프론트엔드로 전달되어 사용자에게 표출됩니다.

3.3 주요 엔진 및 기능 설계

본 프로젝트의 핵심 가치인 ‘자기주도 학습을 통한 사고의 확장 유도’를 실현하기 위해, 멀티모달 전처리, **RAG** 기반 대화 엔진, 그리고 데이터 시각화 리포트 기능을 중심으로 다음과 같이 주요 모듈을 도입하고 설계하였습니다.

1) 멀티모달 학습 자료 통합 전처리 엔진 (**Pipeline App**)

- 구현 목적: **PDF**, 손필기 이미지, 강의 음성 등 파편화된 비정형 학습 데이터를 텍스트로 추출하여 단일화된 지식 베이스를 구축합니다.
- 도입 모듈 및 구현 방법:
 - **PDF** 텍스트 추출: **PyMuPDF** 라이브러리를 사용하여 기본 디지털 문서의 텍스트 레이어를 빠르고 정확하게 추출합니다.
 - 손필기 및 수식 **OCR**: 인식 난이도가 높은 개인 손글씨와 복잡한 전공 수식은 **Gemini 2.5 Flash**의 멀티모달 비전 **API**를 활용하여 고품질의 텍스트로 변환(**OCR**)합니다.
 - 음성 텍스트 변환(**STT**): 교수님의 강의 녹음 파일은 **OpenAI Whisper** 모델을 통해 타임스탬프 정보가 포함된 텍스트 데이터로 변환합니다.
 - 청킹(**Chunking**) 및 벡터화: 추출된 모든 텍스트는 논리적 흐름 유지를 위해 의미 단위의 청크(**Chunk**)로 분할합니다. 이후 **Gemini-Embedding-001** 모델을 거쳐 고차원 벡터로 변환되며, **PostgreSQL(pgvector)** 데이터베이스에 최종 저장됩니다.

2) RAG 기반 소크라테스식 문답 AI 엔진 (RAG & Chat App)

- 구현 목적: AI의 환각 현상을 차단하고, 학습자에게 정답을 직접 제공하는 대신 능동적인 사고를 유도하는 맞춤형 튜터링 환경을 조성합니다.
- 도입 모듈 및 구현 방법:
 - 문맥 검색(Retrieval) 모듈: 사용자로부터 답변이 입력되면 **Gemini-Embedding-001**로 벡터화한 뒤, 이후 **pgvector**의 고속 유사도 검색(L2 Distance 거리 측정 방식)을 사용하여 DB 내에서 가장 연관성이 높은 상위 K개의 강의 맥락(Context)을 추출합니다.
 - 답변 생성(Generation) 모듈: 검색된 강의 Context와 사용자의 질문을 결합하여 **Gemini API**로 전달합니다. 이때 AI가 단순 정보 전달자가 아닌 튜터로서 역할하도록 소크라테스식 페르소나 프롬프트를 적용하여 답변을 생성합니다.

3) 사고 경로 분석 기반의 맞춤형 학습 리포트 엔진 (Report App)

- 구현 목적: 대화 종료 후 대화 로그를 정량적으로 분석하여, 학습자에게 본인의 취약점과 사고 흐름을 객관적으로 보여주는 시각적 피드백 리포트를 제공합니다.
- 도입 모듈 및 시각화 방법:
 - 데이터 수집 및 가공 모듈: **FastAPI** 기반의 Report App 모듈을 구현하여, **ChatMessage** 테이블에 기록된 대화 로그를 조회합니다. 이를 분석하여 핵심 개념의 빈도와 이해도 타임라인 데이터를 가공합니다.
 - 개념 트리(Concept Tree) 시각화: 대화 중 다루어진 핵심 키워드 간의 유기적 관계를 추출하여 마인드맵 형태로 시각화합니다. 프론트엔드에서는 **react-d3-tree** (또는 **React Flow**) 라이브러리를 활용하여 데이터 구조를 렌더링합니다.
 - 이해도 타임라인 시각화: 대화 흐름 속에서 논리적 혼동을 느꼈던 지점(Confusion)과 이해가 완성된 지점(Progress)을 시계열 데이터로 추출하여 타임라인 그래프로 제시합니다.

3.4 주요 기능의 구현

앞서 설계된 주요 모듈들이 시스템 내에서 어떻게 상호작용하는지, 전체적인 데이터 제어 흐름과 핵심인 AI 프롬프트 연동 방식을 상세히 기술합니다.

1) 주요 기능 데이터 흐름 (Data Flow)

① 인증 및 세션 관리 흐름 (Auth & Lecture App)

1. 사용자가 이메일과 비밀번호를 통해 로그인을 요청하면, **Auth & Lecture App**은 **PostgreSQL DB**에서 회원 정보를 검증한 뒤 안전한 **JWT** 토큰을 발급합니다.
2. 사용자가 새로운 강의실을 개설하거나 기존 세션에 진입할 때, 서버는 **DB**에 해당 메타데이터를 저장하고 '사용자-강의-세션' 간의 관계를 매핑하여 개인화된 학습 환경을 준비합니다.

② 멀티모달 전처리 및 지식 베이스 구축 흐름 (Pipeline App)

1. 사용자가 **PDF**, 이미지, 음성 등 학습 자료를 업로드하면 **Pipeline App**이 비동기 방식으로 이를 수신하여 파일 타입별 전처리 파이프라인을 가동합니다.
2. **PyMuPDF**(이미지 변환), **Whisper AI**(STT), **Gemini Vision API**(OCR)를 통해 비정형 데이터를 디지털 텍스트로 전환하며, 추출된 텍스트는 **Recursive Character Text Splitter**를 통해 문맥이 유지되는 의미 단위(**Chunk**)로 분할됩니다.
3. 분할된 청크는 **Gemini-Embedding-001** 모델을 통해 벡터화된 후, **PostgreSQL(pgvector)**에 **L2 Distance** 인덱스와 함께 저장되어 실시간 유사도 검색이 가능한 지식 베이스로 구축됩니다.

③ RAG 기반 소크라테스식 질의응답 흐름 (RAG & Chat App)

1. [선제적 발화] 자료 저장이 완료됨과 동시에 시스템은 문서 요약본을 바탕으로 학습자에게 첫 번째 진단 질문을 먼저 던짐으로써 능동적인 학습을 유도합니다.
2. [지식 검색 및 답변 생성] 학습자가 AI의 질문에 답변하면 **RAG & Chat App**은 해당 답변의 벡터를 활용하여 **pgvector DB**에서 가장 관련성 높은 문맥(**Top-k**)을 실시간으로 검색합니다.

3. [소크라테스식 튜터링] 검색된 문맥, 이전 대화 이력, 그리고 '정답 노출 금지 및 단계적 힌트 제공' 원칙이 담긴 시스템 프롬프트를 결합하여 **Gemini API**를 호출합니다. 생성된 소크라테스식 역질문 응답은 다시 클라이언트에 전달됩니다.

④ 학습 사고 경로 분석 및 시각화 흐름 (Report App)

1. 사용자가 학습 리포트 생성을 요청하면, **Report App**은 **SQLAlchemy**를 통해 **DB**에 누적된 해당 세션의 전체 대화 로그를 호출합니다.
2. 내부 분석 로직을 통해 대화 속 핵심 키워드를 추출하고, 학습자의 사고 확장 과정을 **JSON** 형태의 노드/엣지 트리 구조 및 이해도 타임라인 데이터로 가공합니다.
3. 최종 가공된 데이터는 **React** 프론트엔드로 전송되며, **react-d3-tree** 등의 라이브러리를 통해 시각화된 개념 트리(마인드맵)와 리포트로 최종 화면에 표출됩니다.

3.5 AI (Gemini API) 프롬프트 엔지니어링 상세 구현 내용

1) 구현 목적

본 시스템은 기존 생성형 AI의 단순 정답 제공 방식에서 벗어나, 학습자의 사고 과정과 개념 이해를 유도하는 소크라테스식 AI 튜터 시스템 구현을 목표로 하였습니다.

이를 위해 **Gemini API** 호출 시 단순 사용자 질문만 전달하는 방식이 아니라, 역할(Role), 강의 자료(Context), 학습 상태(Response Logic), 제약 조건(Constraints) 등을 포함한 구조화된 **System Prompt**를 동적으로 생성하여 함께 전달하였습니다.

또한 AI가 단순 요약형 응답이나 즉답형 답변을 생성하지 않도록 제어하고, 업로드된 강의 자료를 기반으로 학생 수준에 맞는 질문과 피드백을 생성하도록 설계하였습니다.

2) 주요 구현 방식

(1) 역할(Role) 기반 Prompt 구성

Gemini API 호출 시 AI의 역할, 현재 학습 과목, 사용자 전공 및 학년 정보를 **Prompt** 내부에 동적으로 주입하였습니다.

예를 들어:

- “자기주도 학습을 돕는 AI 튜터 Qureka”
- “전공 및 학년 수준에 맞는 전문 용어 사용”
- “강의 자료 기반 학습 수행”

등의 역할 정보를 명시하여 범용 챗봇이 아닌 특정 학습 환경에 최적화된 AI 튜터처럼 동작하도록 구현하였습니다.

또한 사용자가 업로드한 강의 자료(Context)와 강의명을 함께 전달하여 현재 학습 중인 수업 흐름과 문맥을 유지하도록 설계하였습니다.

(2) 강의 자료 기반 **Grounding** 적용

AI Hallucination(환각 현상)을 최소화하기 위해 모든 질문과 피드백은 업로드된 강의 자료를 기반으로 생성되도록 제한하였습니다.

이를 위해 **Prompt** 내부에 다음과 같은 규칙을 포함하였습니다.

- 모든 질문과 피드백은 반드시 강의 자료 기반으로 생성
- 강의 자료 범위를 벗어난 답변 제한
- 슬라이드 번호 및 핵심 용어 활용
- 강의 자료 원문 표현 최대한 유지
- 반복·강조된 개념 우선 활용
- 정답의 근거는 반드시 강의 자료에서 찾도록 제한

또한 강의 자료 외부 답변이 들어올 경우: “해당 내용은 강의 자료에서 확인할 수 없습니다.”

와 같은 정책을 적용하여 자료 기반 학습 흐름이 유지되도록 구현하였습니다.

(3) 소크라테스식 질문 생성 전략

기존 생성형 AI의 결과 중심 응답 문제를 해결하기 위해 **Prompt** 내부에 정답 직접 제시 금지 규칙을 명시하였습니다.

이를 위해 다음과 같은 질문 전략을 설계하였습니다.

- **Why / How / Compare** 중심 질문 생성
- 단답형 질문보다 논리적 연결 관계 중심 질문 수행
- 한 번에 하나의 핵심 개념만 질문
- 학생의 직전 답변 핵심 단어를 기반으로 후속 질문 생성

- 동일 개념 반복 질문 방지
- 조건·원인·비교·예외 상황 중심 사고 유도

또한 질문 개수 제한, 질문 길이 제한, 사고량 제한 등의 **Constraint**를 함께 부여하여 실제 튜터와 유사한 상호작용 흐름을 구현하였습니다.

(4) 사용자 응답 기반 동적 **Response Logic** 구현

Gemini API 요청 시 사용자의 이전 대화 로그를 배열 형태로 함께 전달하여 대화의 문맥(Context Window)을 유지하였습니다.

이후 학생의 응답 유형에 따라 **Prompt** 내부 지시 방향을 동적으로 변경하였습니다.

① 학생이 정답에 가까운 경우

- 짧은 긍정 피드백 후 심화 질문 수행
- 전제 조건, 예외 상황, 인접 개념 비교 질문 생성
- 동일 개념 반복 대신 사고 깊이 확장 수행

② 학생이 틀린 답변을 한 경우

- 직접적인 오답 선언 대신 논리적 모순 발견 유도
- 난이도를 단계적으로 낮춘 기초 질문 수행
- 비교 질문 및 반례 기반 재사고 유도

③ 학생이 “모르겠다”고 응답한 경우

- 직접 정답 제공 대신 힌트 기반 질문 수행
- 슬라이드 번호, 핵심 키워드, 이전 맥락 제공
- 단순 반복 유도 대신 사고의 출발점 제공

이를 통해 사용자의 이해 수준과 인지 상태에 따라 적응적으로 반응하는 **AI** 튜터링 흐름을 구현하였습니다.

(5) **Few-shot Learning** 기반 대화 패턴 제어

Prompt 내부에 실제 대화 예시(Few-shot Example)를 포함하여 Gemini 모델이 원하는 질문 흐름과 피드백 스타일을 학습하도록 설계하였습니다.

특히 다음 상황별 예시를 제공하였습니다.

- 학생이 정답에 가까운 경우
- 학생이 오답을 말한 경우
- 학생이 “모르겠다”고 답변한 경우

이를 통해 모델이 단순 설명형 응답이 아닌 실제 튜터와 유사한 소크라테스식 문답 흐름을 안정적으로 생성하도록 유도하였습니다.

3) 실제 **System Prompt** 일부

1. Role & Context (역할 및 맥락)

- 당신은 누구인가: 자기주도 학습을 돕는 AI 튜터 'Qureka'입니다.
- 현재 학습 중인 과목: `{{lecture_title}}`
- 사용자: 당신 앞에 있는 학생은 `{{dept}}` 학과 `{{grade}}`학년 전공자입니다.
- 목표: 사용자가 업로드한 [강의 자료]를 분석하여 단순 요약이 아닌 소크라테스식 문답법을 통해 학생이 스스로 개념을 깨우치고 사고를 확장하도록 돕는 것입니다.

2. Prime Directives (핵심 지시사항)

A. 엄격한 자료 기반성 (Strict Grounding)

- 모든 질문과 피드백은 반드시 제공된 [강의 자료]의 내용과 팩트에 근거해야 합니다.
- 강의 자료 범위를 벗어난 질문에는 "해당 내용은 강의 자료에서 확인할 수 없습니다."라고 답변하세요.
- 배경지식을 활용하되, 정답의 근거는 반드시 강의 자료에서 찾아야 합니다.

B. 소크라테스식 질문 전략 (Socratic Method)

- 학생에게 절대 정답을 먼저 말하지 마세요.
- **Why / How / Compare** 중심 질문을 사용하세요.
- 한 번의 응답에서는 질문을 1개만 생성하세요.

C. 답변에 따른 대응 로직 (Response Logic)

- 학생이 정답에 가까운 경우: 심화 질문 생성
- 학생이 틀린 답변을 한 경우: 논리적 모순 발견 유도
- 학생이 "모르겠다"고 답변한 경우: 슬라이드 번호 및 핵심 키워드 기반 힌트 제공